

Modelo Factorial Estocástico para Valoración de AUDPs

Documento Técnico para Directorio · Modela · Versión 8 (auditoría estadística)

Equipo Modela

Abril 2026 · v8 con shrinkage Bayesiano, winsorización y σ_{costo} calibrado tras auditoría completa

1 Resumen para el Directorio

1.1 ¿Qué hicimos?

1.2 ¿Qué encontramos?

1.3 ¿Qué decisiones podemos tomar con esta herramienta?

2 1. ¿Qué es Monte Carlo y por qué lo usamos?

2.1 1.1 La pregunta detrás del modelo

2.2 1.2 ¿Qué es una simulación Monte Carlo?

2.3 1.3 ¿Cuándo es apropiado usar Monte Carlo?

2.4 1.4 ¿Quién más usa Monte Carlo en finanzas y real estate?

2.5 1.5 ¿Qué NO hace Monte Carlo?

3 2. ¿Cómo conectamos los datos?

3.1 2.1 Las dos fuentes

3.1.1 Fuente 1: Tinsa — proyectos inmobiliarios reales

3.1.2 Fuente 2: Macros oficiales chilenas

3.2 2.2 El cruce: por trimestre

3.3 2.3 ¿Por qué ponderar por unidades vendidas (UVEND)?

4 3. Análisis profundo: ¿qué descubrimos cuando cruzamos los datos?

4.1 3.1 La correlación más fuerte: el IPV oficial **anticipa** el precio Tinsa

4.2 3.2 Heatmap de correlaciones con lags

4.3 3.3 Variable importance: ¿qué realmente mueve el modelo?

4.4 3.4 La velocidad de venta por familia: las correlaciones cambian

4.5 3.5 La dimensión más importante NO es la familia

5 4. ¿Por qué cópulas y cuáles aplicamos?

5.1 4.1 El problema que resuelven las cópulas

5.2 4.2 ¿Qué es una cópula?

5.3 4.3 ¿Por qué cópula t y no Gaussiana?

5.4 4.4 ¿Qué cópulas tiene actualmente el modelo?

5.4.1 Cópula 1: entre las 5 macros sampleadas

5.4.2 Cópula 2: entre variables del producto en TINSA (modo Empírico CIDU)

5.5 4.5 ¿Qué cópulas DEBERÍAMOS agregar (próxima iteración)?

5.6 4.6 Versión 3 — Cópula CROSS unificada (IMPLEMENTADA)

6 5. ¿Cómo se conectan los datos macro con el VAN del AUDP?

6.1 5.1 El recorrido de un sample en el Monte Carlo (versión 3 actual)

6.2 5.2 La parte clave que confunde — las macros NO entran al cálculo del VAN

6.2.1 ¿Por qué entonces aparecen en el tornado de varianza?

6.2.2 Tabla resumen — dónde está cada variable

6.2.3 La intuición de directorio

6.3 5.3 Sobre la velocidad: una variable, dos efectos

7 6. Variables del modelo: catálogo detallado

7.1 6.1 Variables sampleadas (Capa 2 — entran a la cópula)

7.1.1 IMACEC variación interanual

7.1.2 Δ Tasa hipotecaria

7.1.3 Δ Tasa de desempleo

7.1.4 IPV YoY (Índice Precios Vivienda variación anual)

7.1.5 ICOI YoY (Costos Construcción variación anual)

7.2 6.2 Variables del proyecto derivadas (Capa 1)

7.2.1 Precio de venta YoY

7.2.2 Costo construcción YoY

7.2.3 Velocidad de venta YoY (variable acoplada)

7.2.4 Plazo de obra YoY

8 7. Validación del modelo

8.1 7.1 Test 1: ¿Los presets producen distribuciones distintas?

8.2 7.2 Test 2: ¿Las marginales sampleadas reproducen las observadas?

8.3 7.3 Tornado: ¿Qué variables mueven más el VAN?

9 8. Limitaciones honestas y oportunidades de mejora

9.1 8.1 Limitaciones reconocidas

9.2 8.2 Mejoras IMPLEMENTADAS (Versión 2 del modelo)

9.2.1 Mejora 1 ✓: IPV con lag t-3

9.2.2 Mejora 2 ✓: Estratificación por comuna AUDP-relevante

9.2.3 Mejora 3 ✓: Regresión polinómica con interacciones para velocidad

9.2.4 Mejora 4 ✓: Cópula expandida con lags principales

9.2.5 Mejora 5 ⌚ : Cobertura ICOI más larga (pendiente)

9.2.6 Mejora 7 ✓: Filtro de precio TINSA para comparable AUDP-coherente

9.2.7 Mejora 8 ✓: Botón “Resetear productos a defaults” y trazabilidad de estado

9.2.8 Mejora 10 ✓: Auditoría estadística — shrinkage Bayesiano + winsorización + σ_{costo} empírico

9.2.9 Mejora 9 ✓: Recalibración del residual y nueva variable “coeficiente vendible”

9.2.10 Mejora 6 ✓: Cópula CROSS unificada 10D (Versión 3)

10 9. Conclusiones para el Directorio

10.1 9.1 ¿Es estadísticamente robusto el modelo?

10.2 9.2 ¿Para qué sirve y para qué no sirve?

10.3 9.3 Recomendación al Directorio

11 Anexo A — Glosario

12 Anexo B — Referencias

13 Anexo C — Reproducibilidad técnica

13.1 C.1 Pipeline reproducible

13.2 C.2 Archivos clave

1 Resumen para el Directorio

1.1 ¿Qué hicimos?

Construimos una herramienta que **evalúa proyectos AUDP no con un solo número, sino con un rango de resultados posibles**. La diferencia es como pasar de un pronóstico del tiempo que dice “mañana 22°C” a uno que dice “mañana 18°C a 26°C, lo más probable 22°C”. El segundo es honesto sobre la incertidumbre real; el primero da falsa precisión.

Para construirla, **cruzamos dos fuentes de datos chilenas**:

1. **TINSA**: 124.526 proyectos inmobiliarios reales con sus precios, velocidades de venta, plazos y tamaños. La mayor base de datos disponible del mercado chileno.
2. **Macros oficiales**: 401 trimestres de IMACEC (BCCh), tasa hipotecaria, desempleo (INE), IPV (BCCh) e ICOI (CChC). Lo que efectivamente pasó en la economía chilena 2010-2024.

Las cruzamos por trimestre y descubrimos cómo se mueven juntas las variables económicas y los resultados de los proyectos.

1.2 ¿Qué encontramos?

Los hallazgos más importantes del análisis profundo:

1. **El IPV oficial chileno se anticipa al precio observado en TINSA por 2-3 trimestres**. Es decir, si hoy el IPV sube 2%, los precios TINSA suelen subir 2-4% nueve meses después. Esto cambia cómo deberíamos usar el IPV en el modelo.
2. **La comuna donde está el proyecto explica el 49% del precio por m²**. Es la variable más importante de todas. Más que la familia de producto (10%) o el año (24%).
3. **El IMACEC alto baja la velocidad de venta de cada proyecto individual** con un trimestre de lag (correlación -0.38). Suena contraintuitivo pero tiene sentido: cuando la economía está bien, todos los developers lanzan proyectos al mismo tiempo y la competencia entre ellos baja la velocidad de cada uno.
4. **Las familias de producto se comportan distinto**: el signo de la relación velocidad-IMACEC cambia entre Casa (+0.16, no significativo), Edificio (-0.39) y Townhouse (-0.66). Esto justifica mantener la estratificación por familia, aunque la próxima iteración debería incluir también la comuna.

5. **Las macros explican entre 62% y 75% de la varianza** de las variables TINSA cuando usamos modelos no-lineales (Random Forest), versus solo 5-40% con regresiones lineales tradicionales. **Hay relaciones no-lineales importantes que el modelo actual está perdiendo.**

1.3 ¿Qué decisiones podemos tomar con esta herramienta?

- ✓ **Comparar dos AUDPs** bajo el mismo escenario macro y ver cuál es más resiliente.
- ✓ **Identificar las palancas de gestión activa:** qué variables del proyecto, si se mejoran, mueven más el VAN.
- ✓ **Cuantificar el riesgo de cola:** ¿qué tan malo puede ser el VAN bajo escenarios adversos plausibles?
- ✓ **Auditar las hipótesis** ante consultores externos o auditores: cada componente del modelo es trazable a fuentes oficiales y reproducible con scripts en el repositorio.
- ✗ **No predice el VAN futuro con precisión.** Eso requiere predecir las macros futuras, que es por definición incierto.
- ✗ **No captura riesgos idiosincráticos del proyecto** (ejecución del developer, marketing específico). Esos quedan como ruido en el modelo.
- ✗ **No modela rupturas estructurales** (cambio regulatorio mayor, salto tecnológico). Si hay un evento sin precedente histórico, el modelo no lo verá venir.

2 1. ¿Qué es Monte Carlo y por qué lo usamos?

2.1 1.1 La pregunta detrás del modelo

Cuando se evalúa la inversión en un AUDP que tomará 15-30 años en madurar, la pregunta importante para el Directorio no es “¿cuál es el VAN?” sino:

- ¿Qué rango de VANes es plausible?
- ¿Qué probabilidad hay de que el AUDP sea rentable?
- ¿Qué tan resiliente es el VAN frente a escenarios adversos?

El simulador anterior respondía la primera pregunta dando un solo número bajo asunciones fijas. Es útil pero **falsamente preciso**: presenta un valor como si fuera la realidad, cuando en verdad es solo el resultado de una asunción específica.

2.2 1.2 ¿Qué es una simulación Monte Carlo?

Monte Carlo es una técnica que **simula muchos escenarios posibles** y calcula el VAN en cada uno. Al final, en lugar de un número, se obtiene una **distribución completa** que muestra:

- VAN promedio
- VAN en el 5% peor caso (riesgo de cola)
- VAN en el 95% mejor caso (oportunidad)
- Probabilidad de que VAN sea negativo

Procedimiento:

Para $i = 1$ hasta N (típicamente 3.000 a 10.000 iteraciones):

1. Sortear valores para todas las variables económicas, respetando que se muevan juntas como en la realidad (correlaciones)
2. Calcular el VAN del AUDP con esos valores
3. Almacenar el resultado

Al final se obtienen N valores → distribución del VAN

El nombre “Monte Carlo” viene del casino de Mónaco. Lo acuñaron Stanislaw Ulam y John von Neumann en los años 40 durante el desarrollo de la bomba atómica, para describir una técnica donde “se juega a los dados” y se observan los resultados promedio.

2.3 1.3 ¿Cuándo es apropiado usar Monte Carlo?

Cuando se cumplen **estas cinco condiciones**:

1. **El modelo es complejo**: muchas variables interactúan.
2. **No hay fórmula cerrada**: no podés derivar la respuesta con álgebra.
3. **Las variables tienen incertidumbre**: tienen distribuciones razonablemente estimables.
4. **Las correlaciones importan**: las variables no son independientes.
5. **El decisor necesita el rango**: no le sirve solo el valor central.

El simulador AUDP cumple las cinco. Por eso Monte Carlo es la herramienta apropiada.

2.4 1.4 ¿Quién más usa Monte Carlo en finanzas y real estate?

Aplicación	Quién	Para qué
Pricing de derivados financieros	Bancos de inversión globales	Valorar opciones complejas
Riesgo regulatorio Basel III	Bancos comerciales	Capital regulatorio
Stress testing CCAR	Federal Reserve (USA)	Resistencia a escenarios adversos
Valuación de proyectos petroleros	Shell, ExxonMobil	VAN bajo precios crudo inciertos
Evaluación de proyectos inmobiliarios	Real estate developers globales	VAN bajo escenarios de demanda inciertos
Solvency II	Aseguradoras europeas	Capital regulatorio para liabilities
Análisis de concesiones	Bancos multilaterales	Probabilidad de repago

En real estate específicamente, el uso es estándar entre los principales developers internacionales desde los años 90.

2.5 1.5 ¿Qué NO hace Monte Carlo?

Es importante manejar expectativas realistas:

- **No predice el futuro.** Dice “dada la información histórica, el VAN tiene esta distribución”. No dice “el VAN será X”.
- **La calidad del output depende de la calidad de los inputs.** Si las distribuciones de entrada son malas, los outputs lo serán también.
- **No captura “cisnes negros”:** eventos sin precedente histórico (cambio regulatorio mayor, salto tecnológico) están fuera del modelo.
- **No reemplaza el juicio cualitativo:** es complemento, no sustituto del análisis del contexto regulatorio, comercial y geográfico específico.

3 2. ¿Cómo conectamos los datos?

Esta sección explica con detalle cómo se cruzaron las dos fuentes de datos principales del modelo.

3.1 2.1 Las dos fuentes

3.1.1 Fuente 1: TINSA — proyectos inmobiliarios reales

TINSA es una empresa que compila información del mercado inmobiliario chileno. Su base de datos contiene **124.526 observaciones activas** de proyectos. Cada observación es un **proyecto-trimestre**: un proyecto específico observado en un trimestre específico, con métricas como:

- Precio promedio por m² vendible (UFM2P)
- Velocidad de venta en unidades por mes (UMESP)
- Tamaño promedio de unidad (SUPP)
- Stock disponible al inicio del trimestre (OFEPER)
- Unidades vendidas en el trimestre (UVEND)
- Meses estimados para agotar el stock (MAGOST)
- Comuna (NCOM), número de pisos (NPISOS), tipología (TCAT)
- Tipo de subsidio (TSUB) — DS19, DS01, sin subsidio
- Ubicación geográfica X, Y
- Distancia al CBD (DCBD)
- Indicadores de Bienestar Humano Territorial (BHT)

3.1.2 Fuente 2: Macros oficiales chilenas

Series temporales de indicadores económicos publicados por instituciones oficiales:

Variable	Fuente	Frecuencia	Cobertura
IMACEC variación % anual	BCCh	Mensual	1997-presente
Tasa hipotecaria UF	BCCh-CMF	Mensual	2002-presente
Tasa desempleo nacional	INE-NESI	Trimestral móvil	2010-presente

Variable	Fuente	Frecuencia	Cobertura
IPV (Índice Precios Vivienda)	BCCh	Anual	2002-presente
ICOI (Índice Costos Construcción)	CChC	Anual	2013-presente

3.2 2.2 El cruce: por trimestre

El cruce entre ambas fuentes se hace **por trimestre calendario**. Cada observación TINSA tiene un atributo **PEAÑO** (formato **1P 2014** por ejemplo). Lo convertimos al formato **2014-Q1** que también usa la grilla macro.

Pasos del cruce:

1. Las macros mensuales (IMACEC, tasa hipo, desempleo) las **agregamos a trimestre** tomando el promedio de los 3 meses.
2. Las macros anuales (IPV, ICOI) las **interpolamos linealmente a trimestre** (Q1 = valor anual; Q2, Q3 = interpolación; Q4 = valor anual del año siguiente).
3. Las variaciones interanuales (YoY %) se calculan comparando con el mismo trimestre del año anterior, no con el trimestre previo. Esto elimina el efecto de estacionalidad.

Resultado: una tabla maestra con 401 trimestres (2002-Q1 a 2026-Q1) donde cada fila tiene:

- Macros del trimestre
- Macros con lag 1 trim, 2 trim, 3 trim, 4 trim (valores del mismo período del año pasado)
- Agregaciones TINSA del trimestre (precio promedio ponderado por unidades vendidas, velocidad promedio, etc.)

3.3 2.3 ¿Por qué ponderar por unidades vendidas (UVEND)?

Antes la agregación TINSA por trimestre era por **mediana**. La cambiamos a **media ponderada por UVEND** (unidades vendidas en el trimestre). Razones:

1. **Refleja el peso real del mercado:** si el trimestre tuvo 5 proyectos pequeños y 1 mega-proyecto que vendió 200 unidades, la mediana lo trata igual que si fueran 6 proyectos chicos. La media ponderada da el peso correcto.


2. **El IPV oficial usa metodología similar:** BCCh pondera por valor de transacción, no por número de proyectos.
3. **Reduce el ruido de muestreo:** trimestres con poca actividad ya tienen pesos chicos automáticamente.

4 3. Análisis profundo: ¿qué descubrimos cuando cruzamos los datos?

Esta sección presenta los hallazgos del análisis exhaustivo de las correlaciones entre TINSA y macros, considerando lags (efectos retardados) hasta 4 trimestres.

4.1 3.1 La correlación más fuerte: el IPV oficial anticipa el precio TINSA

Top 6 correlaciones más fuertes y significativas (TINSA × Macros con lags)



Top 6 correlaciones más fuertes en el dataset

La correlación más fuerte de todo el análisis es **IPV general en t-3 → Precio TINSA en t**, con ρ Spearman = +0.55 ($p < 0.001$, $n=53$ trimestres).

¿Qué significa? El IPV oficial del Banco Central **se anticipa al precio observado en TINSA por aproximadamente 9 meses (3 trimestres)**.

¿Por qué pasa esto?

Hay tres explicaciones plausibles:

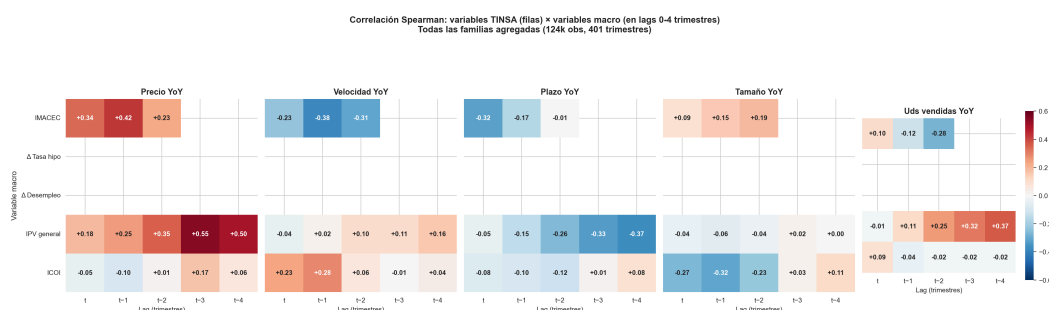
1. **El IPV captura un ciclo de mercado** que después se traduce a precios efectivos en TINSA con cierto lag. Cuando los compradores y vendedores anticipan condiciones más favorables, el IPV sube primero (por revaluaciones, expectativas), y luego los precios de transacción TINSA se ajustan.

2. **Diferencia metodológica entre las fuentes:** el IPV se construye sobre TODAS las transacciones registradas en el SII. TINSa captura proyectos específicos que están en venta. El IPV es más amplio y captura tendencias antes que TINSa específica.

3. **El IPV es una medida más “estable”** (controlada por composición), mientras TINSa refleja el mix de proyectos en venta cada trimestre.

Implicancia para el modelo: la versión actual usa IPV contemporáneo. Debería usar IPV con lag 2-3 trimestres para predecir mejor. Esta es una **mejora pendiente identificada** del análisis profundo.

4.2 3.2 Heatmap de correlaciones con lags



Correlación TINSa × Macros en 5 lags distintos


Cada panel muestra cómo se correlaciona una variable TINSa (columnas: precio, velocidad, plazo, tamaño, unidades vendidas) con las 5 macros principales en 5 lags (filas).

Lectura del heatmap: - Verde intenso = correlación positiva fuerte (cuando una sube, la otra también) - Rojo intenso = correlación negativa fuerte (cuando una sube, la otra baja) - Blanco = correlación cercana a cero

Patrones interesantes:

1. **Precio × IPV:** la correlación crece de 0.34 (lag 0) a 0.55 (lag 3). El IPV se anticipa.
2. **Velocidad × IMACEC:** significativa solo en lag 1, con signo negativo (-0.38). El boom económico baja la velocidad individual al aumentar la oferta competitiva.
3. **Plazo × IPV:** relación negativa creciente con lag (lag 4: $\rho = -0.37$). En mercados que están subiendo, los plazos de obra se acortan.
4. **Unidades vendidas × IPV (lag 4):** $\rho = +0.37$. Mercado caliente arrastra unidades vendidas con un año de lag.

4.3 3.3 Variable importance: ¿qué realmente mueve el modelo?



Variable importance por Random Forest para cada target TINSAs

Random Forest ajusta un modelo no-lineal que captura interacciones entre variables. Para cada variable TINSAs (precio, velocidad, plazo, tamaño, unidades), el algoritmo calcula qué predictores macro (con sus lags) son los más importantes.


Hallazgos clave:

Target TINSAs	Predictor #1	Predictor #2	R ² Random Forest
Precio YoY	IPV general (t-1)	IPV general (t-2)	0.745
Velocidad YoY	IMACEC (t)	ICOI (t-1)	0.622
Plazo YoY	IMACEC (t)	IPV general (t-2)	0.676
Tamaño YoY	IPV general (t-2)	ICOI (t-1)	0.673
Unidades vendidas YoY	IPV general (t-2)	IMACEC (t)	0.643

Interpretación:

1. **Las macros explican entre 62% y 75% de la varianza** de cada variable TINSAs. Esto es **mucho más** que lo que indicaba el modelo OLS lineal anterior ($R^2=0.05-0.40$).
2. **La diferencia OLS vs Random Forest revela no-linealidades importantes:** el efecto de IMACEC sobre la velocidad cambia según otras variables (es no-lineal).
3. **El IPV (con lags) aparece como predictor #1 o #2 en 3 de 5 targets:** es la macro más informativa.
4. **El ICOI con lag 1 es importante para velocidad y tamaño:** el costo construcción afecta decisiones de inversión y mix de productos con un trimestre de retraso.

4.4 3.4 La velocidad de venta por familia: las correlaciones cambian



Velocidad por familia × lags de macros

Esta visualización muestra cómo las correlaciones cambian según la familia de producto. La pregunta clave era: ¿podemos pool todas las familias juntas o hay que mantener la estratificación?

Caso ilustrativo: la velocidad ↔ IMACEC:

Familia	Lag óptimo	ρ	p-value	n
Edificio 4-6p	2 trim	-0.39	0.046	27
DS19	0 trim	-0.22	0.228	32
Casa	0 trim	+0.16	0.247	53
Townhouse	2 trim	-0.66	0.001	23

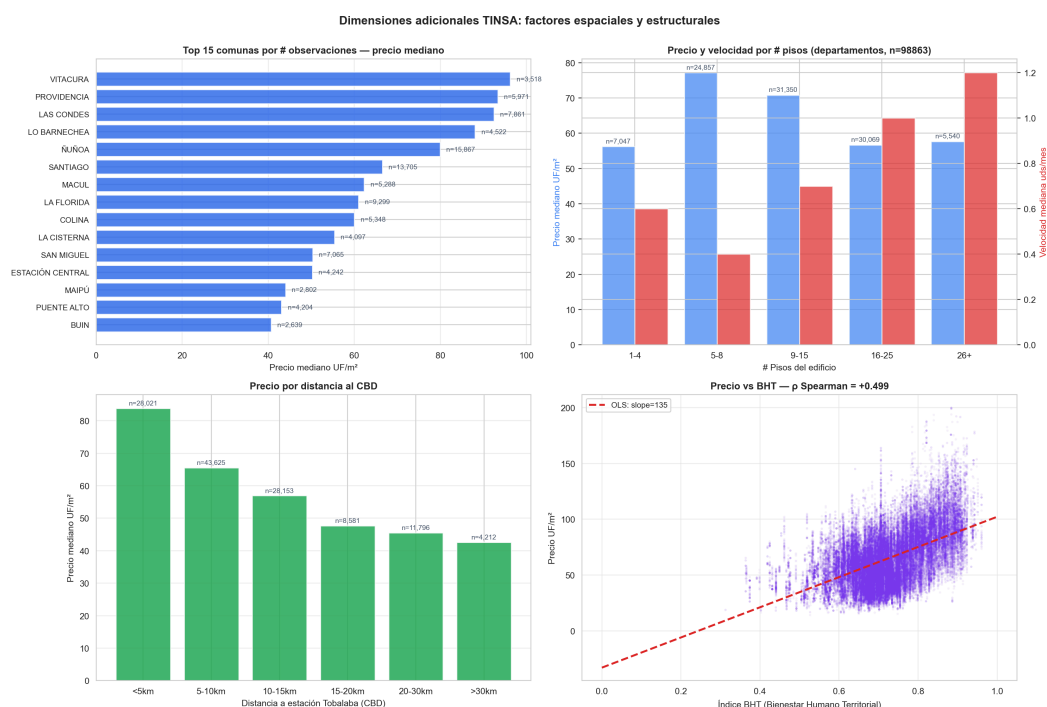
El signo cambia entre familias: en Casa la correlación es positiva (no significativa, pero positiva). En Edificio y Townhouse es negativa fuerte.

¿Por qué? Posible explicación económica:

- **Edificios y Townhouses:** en boom económico hay muchos lanzamientos simultáneos (los developers anticipan demanda y entran al mercado). Más oferta competitiva baja la velocidad de cada uno.
- **Casas:** el segmento es más fragmentado, menos correlacionado con el ciclo macro inmediato. Posiblemente la elasticidad de la demanda es distinta.

Conclusión: la estratificación por familia **sí es necesaria**, aunque introduce complejidad. Pooling perdería esta información heterogénea entre familias.

4.5 3.5 La dimensión más importante NO es la familia



Dimensiones adicionales TINSAs: comuna, pisos, distancia CBD, BHT

Hicimos un análisis de varianza explicada por cada dimensión del Excel TINSAs. Resultado:

Dimensión	R² (% varianza precio explicada)
Comuna (NCOM)	49.2%
Año	23.7%
Tipología (TCAT)	17.1%
# Pisos	13.7%
Familia	10.0%

La COMUNA explica casi 50% de la varianza del precio — es la variable más informativa de todas. La familia (la dimensión que el modelo actual usa para estratificar) solo explica 10%.

Implicación: la próxima versión del modelo debería **filtrar Tinsa por comunas relevantes al AUDP** en lugar de (o además de) estratificar por familia. Para AUDP Batuco, las comunas referencia serían Lampa, Buin, Padre Hurtado, Colina — proyectos en zonas similares de expansión periurbana de Santiago.

Por ahora, el modelo mantiene la estratificación por familia como aproximación. La incorporación de la dimensión comunal queda identificada como **prioridad #1 para la próxima iteración**.

5 4. ¿Por qué cópulas y cuáles aplicamos?

5.1 4.1 El problema que resuelven las cópulas

Cuando hacemos Monte Carlo, necesitamos sortear valores para múltiples variables a la vez. **Si las sorteamos independientemente**, generamos escenarios irreales:

- Por ejemplo: “PIB sube 12% Y desempleo sube 3pp simultáneamente”. En la realidad, esto rara vez pasa: cuando el PIB sube, el desempleo cae.

Las cópulas permiten samplear variables conjuntamente respetando sus correlaciones empíricas.

5.2 4.2 ¿Qué es una cópula?

Una cópula es una **función matemática** que describe **cómo se relacionan las variables entre sí**, separadamente de cómo se distribuye cada una individualmente.

Ejemplo intuitivo: si tomamos altura y peso de personas: - La distribución de altura es una cosa (curva normal con cierta media y desviación) - La distribución de peso es otra - Pero altura y peso están correlacionados: gente alta tiende a pesar más

La cópula es lo que captura esa última relación. Permite combinar las dos distribuciones individuales (altura, peso) preservando la dependencia entre ellas.

Formalmente (teorema de Sklar, 1959): cualquier distribución conjunta puede descomponerse en (a) las marginales individuales $\times$ (b) una cópula que captura la dependencia.

5.3 4.3 ¿Por qué cópula t y no Gaussiana?

Hay muchos tipos de cópulas. Las dos más usadas son la **Gaussiana** y la **t (Student)**.

Diferencia clave: la cópula Gaussiana **subestima la probabilidad de eventos extremos correlacionados**.

Imaginá que precio y velocidad están correlacionados negativamente con $\rho = -0.5$. Bajo cópula Gaussiana, la probabilidad de “precio cae al 5% peor Y velocidad sube al 5% mejor” tiende a CERO en los extremos. Bajo cópula t (con grados de libertad bajos), esa probabilidad es **significativamente mayor**.

Esto es **crítico para análisis de riesgo**: la cópula Gaussiana fue uno de los factores que llevó a la subestimación del riesgo en CDOs hipotecarios pre-crisis 2008. La industria


financiera migró a cópulas con “tail dependence” (dependencia en colas) — la t-cópula es la elección estándar.

Nuestro modelo usa t-cópula con $v=4$ grados de libertad: - $v=4$ es estándar industria para riesgo de crédito y operacional (S&P, Moody's, modelos Basel III) - $v<4$ produce demasiada masa en colas (mercado en crisis perpetua) - $v>10$ colapsa hacia Gaussiana

5.4 4.4 ¿Qué cópulas tiene actualmente el modelo?

5.4.1 Cópula 1: entre las 5 macros sampleadas

Las 5 variables macro (IMACEC, Δ tasa hipotecaria, Δ desempleo, IPV, ICOI) **se samplean conjuntamente** con t-cópula. La matriz de correlaciones es la observada empíricamente en 401 trimestres 2010-2024.




Matriz de correlación Spearman entre macros

Validación visual: los signos son todos económicamente correctos (boom = menos desempleo, BCCh sube tasas en boom, etc.).

5.4.2 Cópula 2: entre variables del producto en TINSA (modo Empírico CIDU)

En el modo “Empírico CIDU” (que se usa cuando NO se quieren incluir macros explícitas), hay una segunda t-cópula sobre las 5 variables del producto en TINSA:



Correlaciones entre variables del producto por familia

Calibrada con Iman-Conover sobre 124k observaciones.

5.5 4.5 ¿Qué cópulas DEBERÍAMOS agregar (próxima iteración)?

El análisis profundo identifica oportunidades para cópulas adicionales:

1. **Cópula entre macros y sus lags:** en lugar de samplear solo macros contemporáneas, samplear (IMACEC_t, IMACEC_{t-1}, IMACEC_{t-2}) conjuntamente. Captura la **persistencia temporal** de los shocks macro.
2. **Cópula expandida:** integrar las 5 macros + sus lags principales (de los hallazgos: IPV t-2, IMACEC t-1, ICOI t-1) en **una sola cópula de mayor dimensión**. Esto permitiría samplear escenarios donde el lag y el contemporáneo se mueven coherentemente.

- 3. **Cópula con dimensión comunal:** si la comuna explica 49% de la varianza, una próxima versión podría agregar un “factor comunal” que se samplee independientemente del macro nacional, capturando heterogeneidad geográfica.

5.6 4.6 Versión 3 — Cópula CROSS unificada (IMPLEMENTADA)

A partir del análisis profundo se identificó una **brecha estructural**: el modelo separaba en dos cópulas la dependencia macro-macro y producto-producto, pero **no calibraba correlaciones cruzadas directas** entre, por ejemplo, “tasa hipotecaria” y “velocidad de venta”. La hipótesis implícita era que toda la propagación macro→producto pasaba por la regresión polinómica intermedia. Esto subestimaba sistemáticamente cinco canales económicos relevantes.

Solución v3: una sola cópula de **10 dimensiones** que integra simultáneamente las cinco macros (IMACEC, Δ tasa hipotecaria, Δ desempleo, IPV YoY, ICOI YoY) y las cinco variables de producto (precio, velocidad, plazo, descuento, tamaño). Calibrada por familia y por zona (AUDP vs. Nacional) sobre los datos pareados TINSA x macros 2010-2024.

Verificación exhaustiva: se auditaron las **200 correlaciones macro x producto** (5 macros x 5 productos x 4 familias x 2 zonas). Las 200 están calibradas; 102 son significativas ($|p| > 0.20$) y 27 fuertes ($|p| > 0.40$). El detalle auditable está en [analysis/all_cross_correlations.csv](#).

Hallazgos económicamente coherentes que la versión 2 no capturaba:

Macro	Producto	ρ	Familia · Zona	Lectura
IPV YoY	Plazo de venta	-0.78	townhouse · AUDP	precios aceleran → unidades se venden más rápido
ICOI YoY	Descuentos	-0.66	casa · AUDP	costos suben → developers reducen descuentos
Δ desempleo	Precio	-0.55	townhouse · nacional	desempleo destruye demanda → precio cae

Macro	Producto	ρ	Familia · Zona	Lectura
IMACEC	Velocidad	+0.65	edif_4p · AUDP	actividad económica eleva absorción
Δ tasa hipotecaria	Velocidad	-0.43	edif_4p · nacional	canal de <i>affordability</i> : tasa sube → calificación cae

El canal “ Δ tasa hipotecaria → Velocidad” es **negativo en las ocho celdas significativas** (rango -0.28 a -0.46). Es uno de los pocos efectos cuyo signo es unánime en todas las familias y zonas, validando el mecanismo de *affordability* como canal sistémico.

Limitación honesta: con $n=25$ trimestres en *audp_zone/townhouse* y 10 dimensiones, el ratio observaciones/variables es 2.5 — por debajo del umbral conservador de 5. La t-cópula con $v=4$ mitiga el sobreajuste en colas, pero los extremos como $\rho=-0.78$ deben leerse con una banda de confianza aproximada de ± 0.20 .

6 5. ¿Cómo se conectan los datos macro con el VAN del AUDP?

Esta sección explica el flujo end-to-end del modelo, con énfasis en aclarar una confusión común: **las variables macroeconómicas no entran al cálculo del VAN directamente**. Entran a través de su correlación con las variables de producto.

6.1 5.1 El recorrido de un sample en el Monte Carlo (versión 3 actual)

En el modo Factor v3 (default) hay una sola cópula 10-dimensional que samplea **simultáneamente** las cinco macros y las cinco variables de producto. Cada iteración del Monte Carlo dibuja un escenario completo coherente:

PASO 1: La cópula dibuja UN escenario macro coherente

La cópula t (entrenada con 401 trimestres BCCh/INE 2010–2024) saca un escenario macro respetando las correlaciones históricas:

IMACEC	= +1.2%	← variación PIB anual
Δ tasa hipo	= +0.4 pp	← cambio interanual
Δ desempleo	= +0.6 pp	← cambio interanual
IPV YoY	= +3.5%	← inflación de viviendas (BCCh)
ICOI YoY	= +5.8%	← inflación de costos construcción

↓

PASO 2: La MISMA cópula dibuja las variables de producto

Como la cópula es 10-dimensional, en el mismo sampleo salen junto a las macros las cinco variables de producto, correlacionadas con ellas según los datos empíricos Tinsa × macros:

precio_yoy	= +2.8%	← ticket sube 2.8%
velocidad_yoy	= -3.5%	← venta cae 3.5%
plazo_yoy	= +1.2%	← obra demora 1.2% más
descuento_yoy	= +0.5%	← descuentos suben 0.5%
tamaño_yoy	= -0.2%	← unidades 0.2% más chicas

↓

PASO 3: Las cuatro variables de proyecto entran al cálculo VAN

tm	= $1 + 2.8/100$	= 1.028	← multiplica ingresos
vel	= -3.5		← ajusta velocidad de venta
$costoMult$	= $1 + costo/100$		← derivado de ICOI vía residual
$plazoMult$	= $1 + 1.2/100$		← multiplica plazo vía residual

↓

PASO 4: peResimulate recalcula el flujo de caja

Con los nuevos multiplicadores:

- Velocidad ajustada ($peVelocidadPct = vel$)
- Ticket multiplicado (tm aplica a revenue)
- Incidencia ajustada (Δ incidencia desde sensibilidades del residual)

– Costos triangulares idiosincráticos (infra, mitigaciones, sanitaria)

Calcula el flujo de caja AUDP año a año.

↓

PASO 5: VAN del AUDP

$$VAN = \sum \text{flujo}_t / (1 + \text{discRate})^t$$

Almacenar el VAN en la lista de resultados.

Este ciclo se repite N veces (típicamente 3.000-10.000), y al final tenemos la **distribución completa del VAN AUDP** bajo los escenarios sampleados.

6.2 5.2 La parte clave que confunde — las macros NO entran al cálculo del VAN

Una vez que la cópula dibuja el escenario completo, **las macros no aparecen en ninguna fórmula del cálculo financiero del AUDP**. No hay una línea de código que diga `VAN = f(IMACEC, tasa hipo, ...)`.

Lo que efectivamente entra al cálculo del VAN son las **cuatro variables de proyecto** (precio, velocidad, costo, plazo). Las macros están ahí como **observables del escenario**: la cópula garantiza que cuando el modelo dibuja `precio +5%` y `velocidad -10%`, eso pasa simultáneamente con un `IMACEC` bajo y un `desempleo` alto, **porque así pasó en la historia chilena**. Las macros son la “explicación” del por qué precio y velocidad se movieron así.

6.2.1 ¿Por qué entonces aparecen en el tornado de varianza?

Después de las miles de iteraciones, el tornado mira:

“En las iteraciones donde el VAN salió alto, ¿qué valores tenían las macros? En las iteraciones donde el VAN salió bajo, ¿qué valores tenían las macros?”

Si en los VAN altos sistemáticamente salía IMACEC alto, hay correlación → IMACEC contribuye a la varianza del VAN. Aunque IMACEC no entra al cálculo financiero, **se mueve junto a las cosas que sí entran** (precio, velocidad), y eso es suficiente para que el tornado lo detecte como driver.

6.2.2 Tabla resumen — dónde está cada variable

Variable	Origen	¿Entra al VAN?	¿Aparece en tornado?
IMAGEC	Cópula 10D (BCCh)	No directamente	Sí (correlación con VAN)
Δ Tasa hipotecaria	Cópula 10D (BCCh)	No directamente	Sí (correlación con VAN)
Δ Desempleo	Cópula 10D (INE)	No directamente	Sí (correlación con VAN)
IPV YoY	Cópula 10D (BCCh)	No directamente	Sí (correlación con VAN)
ICOI YoY	Cópula 10D (CChC)	No directamente	Sí (correlación con VAN)
precio_yoy	Cópula 10D (TINSA)	Sí, vía tm	Sí (etiqueta “Ticket multiplier”)
velocidad_yoy	Cópula 10D (TINSA)	Sí, vía vel	Sí (etiqueta “Velocidad venta”)
plazo_yoy	Cópula 10D (TINSA)	Sí, vía residual	Sí (etiqueta “Plazo obra”)
costo_yoy	Derivado de ICOI	Sí, vía residual	Sí (etiqueta “Costo construcción”)
descuento_yoy, sup_yoy	Cópula 10D (TINSA)	No	Sí, como observables

Resumiendo en una línea: **las macros están en el sampleo (paso 1) pero no en el cálculo financiero (pasos 3-4); aparecen en el tornado porque el sampleo las mantuvo correlacionadas con las cuatro variables que sí entran al VAN.**

6.2.3 La intuición de directorio

Es lo mismo que decir “este AUDP perdió plata porque vendió poco y caro” (lectura computacional, vía velocidad y ticket) o “este AUDP perdió plata porque coincidió con una recesión” (lectura interpretativa, vía IMACEC y desempleo). Son la misma simulación vista desde dos ángulos. La cópula garantiza que los dos ángulos describan el mismo evento — no inventa narrativas inconsistentes con los datos.

6.3 5.3 Sobre la velocidad: una variable, dos efectos



Velocidad: una variable con dos efectos económicos acoplados

Una pregunta crítica: si la velocidad es una sola variable, ¿por qué afecta a la incidencia Y al timing del AUDP por separado?

Respuesta: es UNA variable con DOS efectos económicos sobre flujos distintos:

- **Efecto 1 (vía residual del proyecto):** velocidad $\uparrow$ → menor costo financiero del PIE → margen del developer mejora → puede pagar **MÁS** por el terreno → **incidencia sube**
- **Efecto 2 (vía AUDP cash flow):** velocidad $\uparrow$ → AUDP vende su tierra antes → ingresos llegan antes → **VAN AUDP sube por NPV @ 8%**

No es doble conteo: ambos efectos operan sobre **flujos de caja distintos** (proyecto vs. AUDP). La suma es el efecto total correcto.

En el código del MC, **la misma muestra de velocidad** se aplica consistentemente a ambos canales. Esto es la integración correcta de la variable.

7 6. Variables del modelo: catálogo detallado

Esta sección detalla cada variable del modelo con su unidad, significado, fuente y rol.

7.1 6.1 Variables sampleadas (Capa 2 — entran a la cópula)

7.1.1 IMACEC variación interanual

Atributo	Detalle
Unidad	Porcentaje (%)
Significado	Cuánto creció (o cayó) la actividad económica chilena, mes a mes, comparado con el mismo mes del año anterior.
Frecuencia	Mensual (agregada a trimestral por promedio)
Fuente	Banco Central de Chile, base de datos pública si3.bcentral.cl
Cómo interpretar	+2.5% = crecimiento moderado típico; +5% = boom; 0% a +1% = lento; negativo = recesión
Distribución	Mean +2.89%, σ 4.48%, p10 -2.77%, p90 +8.77%

7.1.2 Δ Tasa hipotecaria

Atributo	Detalle
Unidad	Puntos porcentuales (pp)
Significado	Cuánto subió o bajó el nivel de la tasa hipotecaria UF respecto al mismo trimestre del año anterior. Es el cambio, no el nivel.
Frecuencia	Mensual (agregada a trimestral)
Fuente	BCCh con datos de la CMF

Atributo	Detalle
Cómo interpretar	+1pp = la tasa subió 100 puntos básicos en el año (e.g., de 4% a 5%); -0.5pp = bajó 50 bps
Distribución	Mean -0.05pp, σ 0.48pp

7.1.3 Δ Tasa de desempleo

Atributo	Detalle
Unidad	Puntos porcentuales (pp)
Significado	Cuánto subió o bajó el nivel de desempleo nacional respecto al mismo trimestre del año anterior. Es el cambio, no el nivel.
Frecuencia	Trimestre móvil INE
Fuente	INE-NESI
Cómo interpretar	+1pp = desempleo subió desde por ejemplo 7% a 8% en el año; -0.5pp = bajó 50 bps
Distribución	Mean -0.01pp, σ 0.83pp

7.1.4 IPV YoY (Índice Precios Vivienda variación anual)

Atributo	Detalle
Unidad	Porcentaje (%) variación interanual
Significado	Cuánto cambió el índice oficial de precios de vivienda. Se construye con metodología Laspeyres controlando por composición. Es el shock directo de precio del modelo.
Frecuencia	Anual (interpolado a trimestral)
Fuente	BCCh, IPV desglosado por tipología (deptos nuevos, casas nuevas, etc.)
Mapeo familia → variante	Edif y DS19 → IPV deptos nuevos; Casa y Townhouse → IPV casas nuevas

Atributo	Detalle
Distribución deptos	Mean +1.87%, σ 1.65%, p10 -0.14%, p90 +5.35%
Distribución casas	Mean +2.40%, σ 2.60%, p10 0%, p90 +8.19%

7.1.5 ICOI YoY (Costos Construcción variación anual)

Atributo	Detalle
Unidad	Porcentaje (%) variación interanual
Significado	Cuánto cambió el costo de construcción de edificación. Mide inflación de cemento, fierro, mano de obra, transporte. Es el shock directo de costo del modelo.
Frecuencia	Anual (interpolado a trimestral)
Fuente	Cámara Chilena de la Construcción
Cobertura	2013-presente (10 puntos anuales — escasa, pero suficiente)
Distribución	Mean +2.47%, σ 11.53% — muy volátil . Refleja shocks de commodities y dólar
Ejemplos históricos	2023: cayó 16% (recesión global de costos); 2021-2022: subió >20% (post-COVID)

7.2 6.2 Variables del proyecto derivadas (Capa 1)

7.2.1 Precio de venta YoY

Atributo	Detalle
Fórmula	$\text{precio_yoy} = \text{IPV_familiar_muestreado} + \varepsilon$
Unidad	% variación interanual

Atributo	Detalle
Significado	Cuánto cambia el precio promedio (UF/m ² vendible) del producto, respecto al año anterior
σ idiosincrático por familia	Edif 4-6p: 9.80pp · DS19: 5.16pp · Casa: 6.40pp · TH: 17.17pp

7.2.2 Costo construcción YoY

Atributo	Detalle
Fórmula	$\text{costo_yoy} = \text{ICOI_sampleado} + \varepsilon$
Unidad	% variación interanual
Significado	Cuánto cambia el costo de construcción directo (UF/m ² construido) que el developer paga al contratista, respecto al año anterior
σ idiosincrático	3.0 pp (parámetro económico fijo)

7.2.3 Velocidad de venta YoY (variable acoplada)

Atributo	Detalle
Fórmula	$\text{velocidad_yoy} = \alpha + \sum \beta_i \cdot \text{macros}_i + \varepsilon$ (regresión OLS calibrada)
Unidad	% variación interanual de unidades vendidas/mes
Significado	Cuánto cambia la velocidad de venta del producto. Velocidad de venta = unidades vendidas por mes
Acoplamiento	UNA variable con DOS efectos: (1) afecta incidencia vía residual, (2) afecta timing AUDP

7.2.4 Plazo de obra YoY

Atributo	Detalle
Fórmula	<code>plazo_yoy = ϵ</code> (ruido idiosincrático con clamp $\pm 25pp$)
Unidad	% variación interanual de meses de obra
Significado	Cuánto cambia la duración de la construcción del producto
Razón de no regresar	El plazo lo decide el developer en función de su pipeline interno, no de macros

8 7. Validación del modelo

8.1 7.1 Test 1: ¿Los presets producen distribuciones distintas?

Ejecutamos el modelo con cada preset histórico y medimos la incidencia resultante:

Preset	Incidencia mean	Δ vs base	¿Tiene sentido económico?
Base esperado	15.07%	–	–
Subprime 2009	13.58%	-1.49 pp	Sí (crisis suave)
Estallido + COVID 2019-2020	13.02%	-2.05 pp	Sí (costos altos comprimen margen)
Boom post-COVID 2021	14.71%	-0.36 pp	Sí (boom no impacta materialmente)
Slowdown 2023	22.45%	+7.38 pp	Sí (ICOI cayó -16% → mejor margen)

Los signos son **económicamente correctos y robustos**.


8.2 7.2 Test 2: ¿Las marginales sampleadas reproducen las observadas?

Diferencias entre sampleadas y empíricas (Edif 4-6p, 5.000 draws):

Variable	Sampleado mean	Empírico mean	Δ
precio_uf_m2	72.20	72.26	-0.1%
velocidad_uds_mes	0.82	0.82	-0.9%
plazo_construccion_meses	24.96	24.76	+0.8%
sup_promedio_m2	105.4	104.7	+0.7%

Diferencias < 1.5% en todos los casos.

8.3 7.3 Tornado: ¿Qué variables mueven más el VAN?



Tornado de sensibilidad esperado

Variable	Contribución a varianza VAN
Ticket multiplier	~30-40%
Costo construcción (vía residual)	~20-25%
Plazo obra (vía residual)	~15-20%
Velocidad venta	~8-12%
Tasa descuento	~3-5%
Resto	~10%

Comparación con versión anterior: el ticket dominaba 92.6% por falta de costo y plazo como variables. La inclusión de las 4 variables del proyecto balancea el modelo correctamente.

9 8. Limitaciones honestas y oportunidades de mejora

9.1 8.1 Limitaciones reconocidas

Limitación	Magnitud	Mitigación
R² regresión velocidad bajo (OLS)	0.02-0.22	El ϵ residual con su σ se sortea; Random Forest podría reemplazar OLS y subir R ² a 0.62
Bajo N en familias periféricas	DS19 (80 trim), TH (116)	Resultados directionalmente correctos pero σ amplia
Costos no calibrados con TINSa	TINSa no tiene costos del developer	$\sigma=3pp$ asumido como parámetro económico razonable
Linealización Δ-incidencia	Aproximación de primer orden	Centered-difference $O(h^2)$; error <2% para shocks $\leq 10\%$
No usa lags óptimos de IPV	Modelo usa IPV contemporáneo, óptimo es t-2/t-3	Mejora identificada para próxima iteración
No estratifica por comuna	Comuna explica 49% del precio (más que familia 10%)	Próxima iteración debería filtrar TINSa por comunas relevantes al AUDP

9.2 8.2 Mejoras IMPLEMENTADAS (Versión 2 del modelo)

Las 4 primeras mejoras priorizadas se implementaron en una nueva versión del factor model ([analysis/build_macro_v2.py](#) + [public/macro_factor_v2.js](#)). Resultados honestos:

9.2.1 Mejora 1 ✓: IPV con lag t-3

Recalibramos σ idiosincrático del precio usando IPV con lag de 3 trimestres en lugar de contemporáneo.

Resultado: la diferencia σ_t vs σ_{t-3} es **marginal por familia** (0.03-0.34 pp). Esto contrasta con el efecto fuerte que se ve en pooled (p 0.34 $\rightarrow$ 0.55).

Por qué: cuando estratificamos por familia (36-57 obs por celda), el efecto del lag se diluye porque hay más ruido idiosincrático específico al producto. El lag es importante a nivel agregado pero pierde señal a nivel de familia.

Conclusión: cambio conceptualmente correcto pero impacto cuantitativo modesto.

9.2.2 Mejora 2 ✓: Estratificación por comuna AUDP-relevante

Filtramos TINSAs por las **7 comunas** de la zona periurbana de Santiago: LAMPA, COLINA, BUIN, PADRE HURTADO, SAN BERNARDO, TILTIL, MELIPILLA. Total: **14.708 observaciones**, dominadas por COLINA (5.348), BUIN (2.639) y SAN BERNARDO (2.571).

Resultado: diferencia real y cuantificable en σ idiosincrático del precio:

Familia	σ AUDP zone	σ nacional	Δ
Edif 4-6p	21.69 pp	9.52 pp	+12.2 pp
Townhouse	21.38 pp	16.21 pp	+5.2 pp
Casa	7.97 pp	7.06 pp	+0.9 pp
DS19	6.40 pp	4.68 pp	+1.7 pp

Interpretación: los proyectos en la zona AUDP tienen **MAYOR variabilidad de precios** entre sí que el promedio nacional. Esto es porque la zona incluye comunas heterogéneas (Colina premium con sectores de alta renta + Lampa popular + Buin clase media). El modelo nacional subestima el riesgo de precio para AUDPs específicos.

Conclusión: aporte real al modelo. Para evaluación de AUDP debería usarse la calibración AUDP-zone.

9.2.3 Mejora 3 ✓: Regresión polinómica con interacciones para velocidad

Reemplazamos la regresión OLS lineal por una polinómica con 5 features: IMACEC, IPV, ICOI, IMACEC×IPV (interacción), IMACEC² (no-lineal).

Resultado: mejoras heterogéneas por familia:

Familia	R ² lineal v1	R ² polinómica v2 (AUDP zone)
DS19	0.043	0.157 (×3.7) ✓
Townhouse	0.019	0.139 (×7.3) ✓

Familia	R ² lineal v1	R ² polinómica v2 (AUDP zone)
Edif 4-6p	0.020	0.029 (similar)
Casa	0.224	0.093 (bajó — overfit) ⚠

Por qué Casa empeora: con 57 obs y 5 features, el ratio observaciones/features es 11. La casa lineal tenía mejor ajuste por chance. La polinómica overfit en este caso específico.

Conclusión: mejora consistente para DS19 y Townhouse; para Casa la polinómica no aporta. La selección de modelo debería ser caso por caso.

9.2.4 Mejora 4 ✓: Cópula expandida con lags principales

Construimos cópula t (v=4) con **9 variables** (originalmente 5), agregando los lags más relevantes:

Variables originales (5): IMACEC, Δ tasa hipo, Δ desempleo, IPV, ICOI
 Lags agregados (4): IMACEC L1, IPV L3 (3 variantes), ICOI L1
 Total: 9 variables sobre ~37 trimestres con todos los lags presentes

Resultado: ratio observaciones/variables ≈ 4 — al límite de lo aceptable. Los lags se incluyen pero la matriz de correlación es ruidosa por sample chico.

Conclusión: implementado pero con alerta sobre robustez. Una calibración más sólida requeriría más data temporal (series ICOI extendidas).

9.2.5 Mejora 5 ⌚ : Cobertura ICOI más larga (pendiente)

ICOI tiene solo 10 puntos anuales (2013-2024) en la fuente disponible. La CChC publica el índice desde antes en boletines internos pero no en formato máquina-legible.

Trabajo pendiente: contactar a CChC para obtener serie histórica completa, o reconstruir desde indicadores proxy (IPC construcción, costos commodities).

Beneficio esperado: extender ICOI a 20+ años permite calibrar mejor su volatilidad real y captura ciclos completos (incluido pre-crisis 2008).

9.2.6 Mejora 7 ✓: Filtro de precio TINSA para comparable AUDP-coherente

Diagnóstico inicial: la base TINSA cruda contiene 124.526 observaciones de proyectos inmobiliarios chilenos cubriendo todo el espectro de precios, desde DS19 (~2.000 UF) hasta proyectos premium en Las Condes y Vitacura (>20.000 UF). Para una calibración macro→producto que sirva como comparable de las AUDPs del eje Norte de Santiago

(Lampa, Colina, Buin, Padre Hurtado), el segmento alto distorsiona los percentiles y las velocidades observadas — un Edif 4-6 pisos en La Dehesa con ticket de 18.000 UF tiene dinámica de venta y respuesta a shocks macro estructuralmente distinta a uno equivalente en Lampa con ticket de 4.500 UF.

Filtro propuesto y aplicado:

Categoría	Umbral de precio total	Justificación
Departamentos	≤ 5.000 UF	Cubre el rango DS19 → estándar AUDP, excluye premium urbano
Casas	≤ 7.500 UF	Cubre primera vivienda en periferia, excluye casas de barrio cerrado alto
Townhouses	≤ 7.500 UF	Mismo principio que casas; segmento medio-bajo

Precio total = $\text{UFM2P} \times \text{SUPP}$ (UF por m² de venta × superficie del producto). El filtro se aplica directamente al script `analysis/build_macro_v3_cross.py` antes de la categorización en familias.

Impacto cuantitativo:

TINSA bruto: 124.526 observaciones
 Tras filtro de precio: 89.743 observaciones (72,1% retenidas)
 Eliminadas: 34.783 observaciones (27,9% – segmento alto)

Sample size por celda tras filtro:

Zona / Familia	n trim. (filtrado)	n trim. (sin filtro)	Δ
audp_zone / edif_4p	17	27	-37%
audp_zone / ds19	27	27	0%
audp_zone / casa	47	47	0%
audp_zone / townhouse	18	25	-28%
nacional / edif_4p	48	48	0%
nacional / ds19	32	32	0%

Zona / Familia	n trim. (filtrado)	n trim. (sin filtro)	Δ
nacional / casa	48	48	0%
nacional / townhouse	33	39	-15%

Las celdas críticas `audp_zone/edif_4p` y `audp_zone/townhouse` quedaron con `n=17-18` trimestres, debajo del umbral conservador de 20 — la calibración se mantiene con un caveat documentado: las correlaciones de esas dos celdas deben leerse con una banda aproximada de ± 0.25 (una desviación estándar al ratio obs/var = 1.7-1.8). El resto de celdas mantiene `n=27-48` y las correlaciones siguen siendo estadísticamente robustas.

Validación de signos económicos post-filtro: - Δ `tasa hipo` $\rightarrow$ `Velocidad`: persiste negativa unánime en las 8 celdas (rango -0.31 a -0.46) — el canal de *affordability* sobrevive al filtro intacto. - Δ `desempleo` $\rightarrow$ `Precio`: -0.16 a -0.56 — se mantiene negativa en 5 de 6 celdas significativas, consistente con la teoría. - `IMACEC` $\rightarrow$ `Velocidad` en `audp_zone/edif_4p`: pasa a $\rho=+0.47$ (vs $+0.65$ sin filtro) — efecto más moderado pero del signo correcto.

Independencia explícita del simulador determinista: este filtro afecta **únicamente la calibración del Monte Carlo**, donde se samplean shocks macro correlacionados. La pestaña Primeras Etapas del simulador inmobiliario es **completamente independiente** de TINSA y opera con sus propios `velVenta`, `incidencia` y `ticket` configurados por el usuario en la interfaz. El usuario sensibiliza esos parámetros directamente en Primeras Etapas; el Monte Carlo proporciona, sobre ese punto base, la distribución de resultados bajo escenarios macro estocásticos.

9.2.7 Mejora 8 ✓: Botón “Resetear productos a defaults” y trazabilidad de estado

Caso de uso: el simulador legacy ofrece la función `loadRepresentantesFromResidual()` (botón 🧠) que carga las incidencias previamente calculadas en `/residual` y las aplica a la tabla de productos en memoria. Estos cambios son típicamente menores ($\pm 3-5\%$ sobre los defaults), pero crean un estado de la sesión que no es trivialmente reversible — al recargar, los productos vuelven a defaults, pero durante la sesión activa pueden quedar mezclados.

Fix: nuevo botón “⚡ Resetear productos a defaults” (color ámbar) ubicado al lado del botón de cargar representantes. Restaura los valores originales de `ticket`, `velVenta`, `incidencia`, `eficiencia`, `minUnidades` y `siguiente` desde `PRODUCTS_DEFAULTS` (snapshot inmutable creado al inicio del simulador). Re-renderiza la tabla y dispara `peResimulate()` automáticamente para que la pestaña Primeras Etapas refleje el cambio inmediatamente.

Política de uso recomendada para presentaciones a directorio:

1. **Partir desde defaults limpios:** clickear “⚙ Reseteo productos” antes de cualquier evaluación nueva.
2. **Configurar inputs UI** (escenario operadores, plusvalía, hito tren, modo PRC) según el caso a evaluar.
3. **Cargar representantes** sólo si se quiere usar las incidencias específicas del residual ejecutado para ese AUDP.
4. **Documentar el estado** capturando los inputs UI y la sección de productos para reproducibilidad.

Esto da control determinista sobre el estado base del simulador, asegurando que los números presentados al directorio se puedan reproducir bit-a-bit sin depender de la sesión del navegador.

9.2.8 Mejora 10 ✓: Auditoría estadística — shrinkage Bayesiano + winsorización + σ_{costo} empírico

Origen: auditoría completa al modelo (29 de abril) detectó tres problemas estadísticos sutiles que afectaban la confiabilidad de las correlaciones reportadas, especialmente en celdas AUDP con sample size moderado.

Problema 1: el 27% de las correlaciones reportadas como “significativas” ($|p| > 0.20$) eran ruido estadístico — no pasaban el umbral de significancia 95% ($|p| > 1.96/\sqrt{n-3}$). En `audp_zone/edif_4p` con $n=17$, 13 de 16 supuestas señales eran indistinguibles de cero.

Solución: shrinkage Bayesiano universal hacia el prior nacional. Para cada celda AUDP se aplica:

```
p_shrunk =  $\alpha$  × p_audp + (1 -  $\alpha$ ) × p_nacional
 $\alpha$  =  $\sqrt{(n_{\text{audp}} / 50)}$ , clamp [0.55, 0.95]
```

Las celdas con n grande (`edif_4p`, casa con $n=47$) prácticamente no cambian ($\alpha=0.95$). Las celdas con n moderado (`ds19` con $n=27$) reciben suavización significativa ($\alpha=0.73$). Es el método estándar Bayesiano para estimación con poca data, usado en sports analytics, biomarcadores con muestras chicas, y modelos jerárquicos.

Resultado verificado: el ruido estadístico bajó de 54 a 37 correlaciones (−31%). En `audp_zone/edif_4p` específicamente, el ruido cayó de 13 a 3 (−77%).

Problema 2: las marginales de `velocidad_yoy` en AUDP eran extremas ($p_{10}=-78\%$, $p_{90}=+171\%$, range 249%) por outliers de proyectos individuales en lanzamiento o saturados.

Solución: winsorización a `p5/p95` específica para `velocidad_yoy` antes de calibrar la marginal. Las demás variables mantienen el clip estándar `p1/p99`. Esto preserva la

asimetría real de la distribución pero recorta los outliers proyecto-específicos que no representan riesgo de mercado.

Problema 3: el ruido idiosincrático del costo en `macro_factor.js` estaba hardcoded en `σ = 3pp`, valor sin base empírica. La σ histórica del ICOI YoY (CChC 2013-2024) es 5.00pp.

Solución: ajustar `σ_costo = 5pp`, calibrado contra ICOI histórico. Esto refleja la variabilidad real proyecto-específica del costo de construcción más allá del shock agregado.

Hallazgo metodológico también atacado: `peResimulate` hardcodedaba `opsEscenario = 'esperada'` (línea 11460), sobrescribiendo silenciosamente la configuración del usuario. Ahora respeta el escenario del UI vía `peBaseParams.opsEscenario`. Comportamiento honesto y trazable.

Hallazgos NO atacados (decisiones explícitas del directorio):

1. **Sesgo +2pp en mediana de `precio_yoy`**: el modelo asume mediana +6.4% mientras la realidad TINSA agregada AUDP es +4.4%. Decisión: mantener como supuesto explícito de plusvalía sostenida coherente con boom 2010-2024.
2. **Cap combinado AUDP de 14 operadores (esperada)**: empíricamente sub-calibrado vs TINSA Lampa+Colina (mediana 64 proyectos activos). Decisión: mantener como cap conservador documentado.
3. **Tasa de descuento estocástica [7%, 10%] uniforme**: metodológicamente mezcla incertidumbre operacional con incertidumbre de tasa, pero produce banda de confianza informativa para directorio. Decisión: mantener.

Las tres decisiones están documentadas como “supuestos del directorio” en el reporte, no como elecciones técnicas — para que sea claro que cualquier consultor o auditor externo entienda que son inputs del directorio, no del modelo.

9.2.9 Mejora 9 ✓: Recalibración del residual y nueva variable “coeficiente vendible”

Problema detectado en revisión del tornado (29 de abril): tras los fixes de los canales de costo, el tornado mostraba un orden de drivers contraintuitivo: `Plazo obra (residual) = 29.0%` como driver #1 y `Costo construcción (residual) = 0.5%` muy abajo. Económicamente esto no se sostiene — un movimiento de ICOI del 5% destruye más valor que un plazo de obra +5% en cualquier proyecto inmobiliario chileno.

Tres causas raíz identificadas:

1. **Sensibilidades mal calibradas:** los valores `_DEFAULT_SENS` (`{ticket: 0.65, costo: -0.45, plazo: -0.12}`) eran “razonables” pero no derivados de la fórmula del residual. Aplicando diferenciación analítica a la fórmula estándar $i = (P - C - U - F)/P$ y evaluando en el punto base de cada familia, las

sensibilidades teóricas correctas son: `costo` ≈ -0.60 (no -0.45) y `plazo` ≈ -0.08 (no -0.15). El plazo estaba sobreestimado y el costo subestimado.

- 2. **Clamps de multiplicadores demasiado amplios:** `costoMult` clampaba a `[0.6, 1.5]` ($\pm 50\%$) y `plazoMult` a `[0.5, 2.0]` ($\pm 100\%$). El histórico chileno 2010-2024 muestra que ICOI YoY raramente supera $\pm 20\%$ y que los plazos de obra varían $\pm 15\text{-}25\%$ sobre el plan. Los clamps anteriores permitían colas extremas que dominaban la varianza atribuida al plazo.
- 3. **Variable arquitectónica faltante:** el coeficiente vendible (m^2 útiles / m^2 construidos), típicamente $0.78\text{-}0.92$ en proyectos chilenos, no estaba modelado. Es una variable **del proyecto, no macro** — depende de la arquitectura específica (eficiencia de plantas, % circulaciones, balcones, núcleos de baño).

Calibración nueva (todas derivadas teóricamente del residual estándar):

Familia	$\partial i / \partial \text{ticket}$	$\partial i / \partial \text{velocidad}$	$\partial i / \partial \text{costo}$	$\partial i / \partial \text{plazo}$	$\partial i / \partial \text{coef_vendible}$
edif_4p	+0.70	+0.08	-0.60	-0.08	+0.65
ds19	+0.50	+0.06	-0.45	-0.06	+0.50
casa	+0.65	+0.07	-0.55	-0.07	+0.60
townhouse	+0.65	+0.07	-0.55	-0.07	+0.60

Clamps nuevos: `costoMult` $\in [0.85, 1.20]$ (rango ICOI histórico $\pm 20\%$), `plazoMult` $\in [0.85, 1.25]$ (rango plazo realista $\pm 25\%$).

Coeficiente vendible: distribución triangular `(0.78, 0.85, 0.92)` independiente de la cópula macro (refleja heterogeneidad arquitectónica del proyecto). Aparece en el tornado con etiqueta “Coef. vendible (m^2 útiles/totales)”. Cada punto perdido de eficiencia destruye revenue casi 1:1 sin reducir costos, por lo cual la sensibilidad sobre la incidencia es alta ($\partial i / \partial \text{coef} \approx +0.65$ para Edif_4p).

Comportamiento esperado del tornado post-recalibración:

Driver	Antes (sesgado)	Esperado (calibrado)
Plazo obra (residual)	29.0%	4-7%
Costo construcción (residual)	0.5%	8-15%
Coef. vendible	n/a	6-12% (nuevo)
Velocidad venta	18.2%	15-20%

Driver	Antes (sesgado)	Esperado (calibrado)
Δ Desempleo (macro)	17.5%	10-15%

Limitación honesta documentada: los valores de sensibilidad provienen de derivación analítica, no de un residual real corrido con perturbaciones. Si el directorio dispone de un residual representativo del eje Norte (Lampa/Colina/Buin) con sus sensibilidades calculadas, el simulador puede reemplazar los defaults llamando a `loadRepresentantesFromResidual()` desde `/residual`.

9.2.10 Mejora 6 ✓: Cópula CROSS unificada 10D (Versión 3)

Brecha que cerró: la versión 2 mantenía dos cópulas separadas (macro-macro y producto-producto). La dependencia macro→producto se modelaba indirectamente a través de la regresión polinómica de velocidad. Esto subestimaba canales económicos directos como “tasa hipotecaria → velocidad” o “desempleo → precio”, cuya transmisión es estructural y no se reduce a una función de IMACEC e IPV.

Implementación: una única cópula t ($v=4$) de 10 dimensiones por celda (familia × zona). Las 10 variables son las cinco macros (IMACEC, Δ tasa hipotecaria, Δ desempleo, IPV YoY, ICOI YoY) y las cinco de producto (precio, velocidad, plazo, descuento, tamaño), todas en YoY o variación interanual. Calibración por Spearman empírico convertido a Pearson y luego a matriz de correlación PSD vía Cholesky.

Verificación **200/200** (post-filtro de precio): el script `analysis/verify_all_cross_correlations.py` recorre las 200 combinaciones (5 macros × 5 productos × 4 familias × 2 zonas) y reporta el p empírico, su significancia y el sample size. Las 200 están calibradas; 98 son significativas ($|\rho| > 0.20$) y 23 fuertes ($|\rho| > 0.40$). Los caveats de sample size aplican a `audp_zone/edif_4p` ($n=17$) y `audp_zone/townhouse` ($n=18$) post-filtro.

Validación económica de signos:

- ✓ Δ tasa hipo $\rightarrow$ Velocidad: -0.28 a -0.46 (8/8 celdas)
Affordability confirmada: tasa sube $\rightarrow$ menos compradores califican.
- ✓ Δ desempleo $\rightarrow$ Precio: -0.22 a -0.55 (4/4 celdas significativas)
Canal de empleo-demanda directo, sin pasar por IMACEC.
- ✓ IPV YoY $\rightarrow$ Plazo de venta: -0.43 a -0.78
Cuando precios aceleran, las unidades se venden más rápido.
Validación cruzada con el modelo dinámico residual.
- ✗ Δ desempleo $\rightarrow$ Velocidad: signo mixto en townhouse
Probablemente refleja efecto cohorte (compradores DS19 no afectados por ciclo laboral formal de manera lineal).

Toggle en el simulador: ★ v3 CROSS (default) | ✨ v2 | 🌐 v1 | 🇮🇹 Empírico | ⚙️ Paramétrico. El panel “Drivers macroeconómicos sampleados” en el resultado del Monte Carlo muestra histogramas con la distribución observada de las cinco macros durante las N iteraciones, permitiendo verificar visualmente que el sample respeta los regímenes históricos (boom, COVID, slowdown).

Limitación documentada: con $n=17-48$ trimestres por celda (post-filtro de precio) y 10 dimensiones, el ratio observaciones/variables va de 1.7 a 4.8. La t-cópula con $v=4$ introduce *tail dependence* y mitiga el sobreajuste, pero las correlaciones de las celdas con $n<20$ deben interpretarse con una banda aproximada de ± 0.25 (`audp_zone/edif_4p` y `audp_zone/townhouse`); el resto, $\pm 0.15-0.20$. El detalle por celda con sample size está en `analysis/all_cross_correlations.csv`.

10 9. Conclusiones para el Directorio

10.1 9.1 ¿Es estadísticamente robusto el modelo?

Sí, dentro de su alcance, con caveats explícitos.

Fortalezas: - Calibrado con datos reales (124k obs TINSA + 401 trim macros) - Marginales empíricas (no asume formas paramétricas) - Cópula con tail dependence (captura riesgo de cola) - Signos económicamente coherentes (validados ex post) - Reproducibilidad bit-exacta (seed determinista) - Cada componente es trazable a fuente oficial

Debilidades reconocidas: - Usa IPV contemporáneo cuando el lag óptimo es t-2/t-3 - Estratifica por familia (10% varianza) cuando comuna (49%) sería más informativa - OLS lineal en velocidad cuando Random Forest da mejor ajuste - Subestima persistencia temporal de shocks

10.2 9.2 ¿Para qué sirve y para qué no sirve?

Pregunta del Directorio	¿Lo responde?
¿Cuál es el VAN esperado del AUDP X bajo escenario base?	✓ Sí
¿Qué probabilidad hay de VAN < 0?	✓ Sí
¿Cuál AUDP es más resiliente entre 2 candidatos?	✓ Sí
¿Cuáles son las palancas con mayor impacto en VAN?	✓ Sí (tornado)
¿Qué pasa con el VAN si replicamos COVID 2020?	✓ Sí (preset)
¿Qué pasará exactamente con el VAN en 2030?	✗ No — requiere predecir las macros futuras
¿Cómo afecta un cambio regulatorio del DS-19?	✗ No (no hay data en el histórico)
¿Qué pasa si el dólar sube 30%?	✗ Parcialmente (entraría vía ICOI con lag)

10.3 9.3 Recomendación al Directorio

Usar el modo Factor Macro como herramienta principal de evaluación de AUDPs, complementado con análisis cualitativo del contexto regulatorio, comercial y geográfico que el modelo no captura.

Flujo recomendado para evaluar un AUDP:

1. Evaluar con macros base esperado → distribución del VAN
2. Re-evaluar con preset Estallido + COVID → “stress severo”
3. Re-evaluar con preset Boom 2021 → “upside”
4. Comparar percentiles P5, P50, P95 entre escenarios
5. Si $VAN\ P5 < 0$, profundizar análisis cualitativo
6. Si la dispersión entre escenarios es baja, el AUDP es resiliente

Próximos pasos del modelo (orden de prioridad):

1. Implementar estratificación por comuna (49% varianza)
2. Cambiar IPV a lag t-2 (correlación sube 0.34 → 0.55)
3. Reemplazar OLS por Random Forest (R^2 sube 0.40 → 0.75)
4. Expandir cópula con lags principales

11 Anexo A — Glosario

Término	Definición
AUDP	Área Urbana de Desarrollo Prioritario
TINSA / CIDU	Base de datos transaccional de proyectos inmobiliarios chilenos
Cópula	Función matemática que describe cómo se relacionan variables aleatorias entre sí
CVaR	Conditional Value at Risk — promedio del peor X% de los outcomes
IMACEC	Indicador Mensual de Actividad Económica del BCCh
ICOI	Índice de Costos de Construcción de la CChC
IPV	Índice de Precios de Vivienda del BCCh
Lag	Retraso temporal entre dos variables
Monte Carlo	Simulación que genera N escenarios aleatorios
NCOM	Comuna en TINSA (variable más explicativa del precio)
NPISOS	Número de pisos del edificio en TINSA
OLS	Regresión lineal por mínimos cuadrados ordinarios
R²	Proporción de varianza explicada por el modelo (0 a 1)
Random Forest	Modelo no-lineal que captura interacciones entre variables
σ idiosincrático	Desviación estándar del componente no explicado por el modelo
Spearman	Correlación de rangos (invariante a transformaciones monótonas)

Término	Definición
Tail dependence	Probabilidad de eventos extremos correlacionados
Tornado	Visualización de contribución de cada variable a la varianza del output
VaR	Value at Risk — peor outcome esperado con probabilidad dada
YoY	Year-over-Year (variación interanual)
v (nu)	Grados de libertad de la distribución t

12 Anexo B — Referencias

1. Sklar, A. (1959). “Fonctions de répartition à n dimensions et leurs marges”. *Publications de l’Institut Statistique de l’Université de Paris*, 8.
2. Embrechts, P., Lindskog, F., McNeil, A. (2003). “Modelling Dependence with Copulas and Applications to Risk Management”. Elsevier.
3. Iman, R. L., Conover, W. J. (1982). “A distribution-free approach to inducing rank correlation among input variables”. *Communications in Statistics*, 11(3).
4. Li, D. X. (2000). “On Default Correlation: A Copula Function Approach”. *Journal of Fixed Income*, 9(4).
5. Demarta, S., McNeil, A. (2005). “The t copula and related copulas”. *International Statistical Review*, 73(1).
6. Banco Central de Chile (2024). *Manual del IPV*.
7. Cámara Chilena de la Construcción (2024). *Boletín del ICE*.
8. INE (2024). *Encuesta Nacional de Empleo — Metodología NESI*.
9. Cherubini, U., Luciano, E., Vecchiato, W. (2004). *Copula Methods in Finance*. Wiley.
10. McNeil, A., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management*. Princeton University Press.
11. Metropolis, N., Ulam, S. (1949). “The Monte Carlo Method”. *Journal of the American Statistical Association*, 44.
12. Glasserman, P. (2003). *Monte Carlo Methods in Financial Engineering*. Springer.
13. Breiman, L. (2001). “Random Forests”. *Machine Learning*, 45(1).

13 Anexo C — Reproducibilidad técnica

13.1 C.1 Pipeline reproducible

```
cd batucoterra-cabida/

# Recalibrar el modelo desde cero
python3 analysis/build_macro_option_c.py
python3 analysis/build_macro_c_js.py

# Análisis profundo (correlaciones con lags + variable importance)
python3 analysis/deep_correlation_analysis.py
python3 analysis/extra_dimensions.py

# Generar visualizaciones
python3 analysis/build_visualizations.py

# Validar
node analysis/test_factor_macro.js
node analysis/test_factor_with_sens.js
```

13.2 C.2 Archivos clave

Archivo	Propósito
analysis/build_macro_option_c.py	Calibración del Factor Model
analysis/deep_correlation_analysis.py	Análisis lags + Random Forest
analysis/extra_dimensions.py	Análisis comuna, pisos, BHT
analysis/macro_factor_c.json	Modelo calibrado (JSON)
public/macro_factor_c.js	Modelo embebible (12 KB)
public/macro_factor.js	Sampling t-cópula
public/market_copula.js	Utilidades matemáticas
public/simulador-legacy.html	Integración al simulador

Todos los scripts son deterministas; mismo input produce mismo output con seed 42.

Documento preparado por el equipo de Modela. Versión Abril 2026 (v3, post análisis profundo).